

FlowCabal 架构设计文档 v3 – Agent 架构

日期: 2026.02.13

本文档基于 v2 设计文档 (EventBus + core-runner) 的进一步演进。核心变化: 引入 Python 后端, Agent 系统, OpenViking 上下文管理。FlowCabal 从浏览器单体应用升级为客户端-服务端架构。

目录

FlowCabal 架构设计文档 v3 – Agent 架构	1
架构决策背景	1
为什么需要 Agent	1
AI 辅助创作的定义	2
为什么必须使用 OpenViking	2
整体架构	2
客户端-服务端分离	2
职责划分	3
两套 LLM 配置	3
Agent 系统设计	3
统一 Agent 循环	3
Prompt 组装管线	4
执行流程 (三角色协作)	4
WebSocket 协议	5
Browser → Python	5
Python → Browser	6
消息流时序	7
完整执行流程	7
OpenViking 项目模型	8
长篇小说的虚拟文件系统结构	8
Agent 如何使用 OpenViking	8
目录结构	9
浏览器端	9
Python 后端	9
与之前设计的关系	9
实施路线	10
阶段一: 基础设施	10
阶段二: Agent 核心	10
阶段三: Agent 高级能力	10
阶段四: 打磨	10

架构决策背景

为什么需要 Agent

paper.typ 提出了三层能力需求:

1. DAG 工作流 + 执行引擎: design_doc.typ 已覆盖, 机械性工作
2. 高级查询函数 + 节点历史/冻结: 扩展 DAG 的控制流原语, 机械性工作

3. Agent + 上下文管理：自主代理监控和介入工作流运行

前两层是机械性实现。第三层是架构性决策。

AI 辅助创作的定义

> 人类定义 **what** (意图、约束、美学标准) 并 **评判质量**。AI 负责 **how** (执行、上下文组装、战术决策)。两者之间的结构/策略层—分解、编排、上下文选择—是 **共享领域**，人类与 AI 都不能独立胜任。

Agent 的角色：填充这个共享领域。不是纯执行器，不是自主创作者，而是 **结构层的协作者**。

为什么必须使用 OpenViking

长篇小说涉及极重的设定管理：角色状态、情节线索、世界观规则、文风约束。一部 8 万字以上的小说，每个节点生成时需要的上下文是 **动态的、层次化的、可追溯的**。

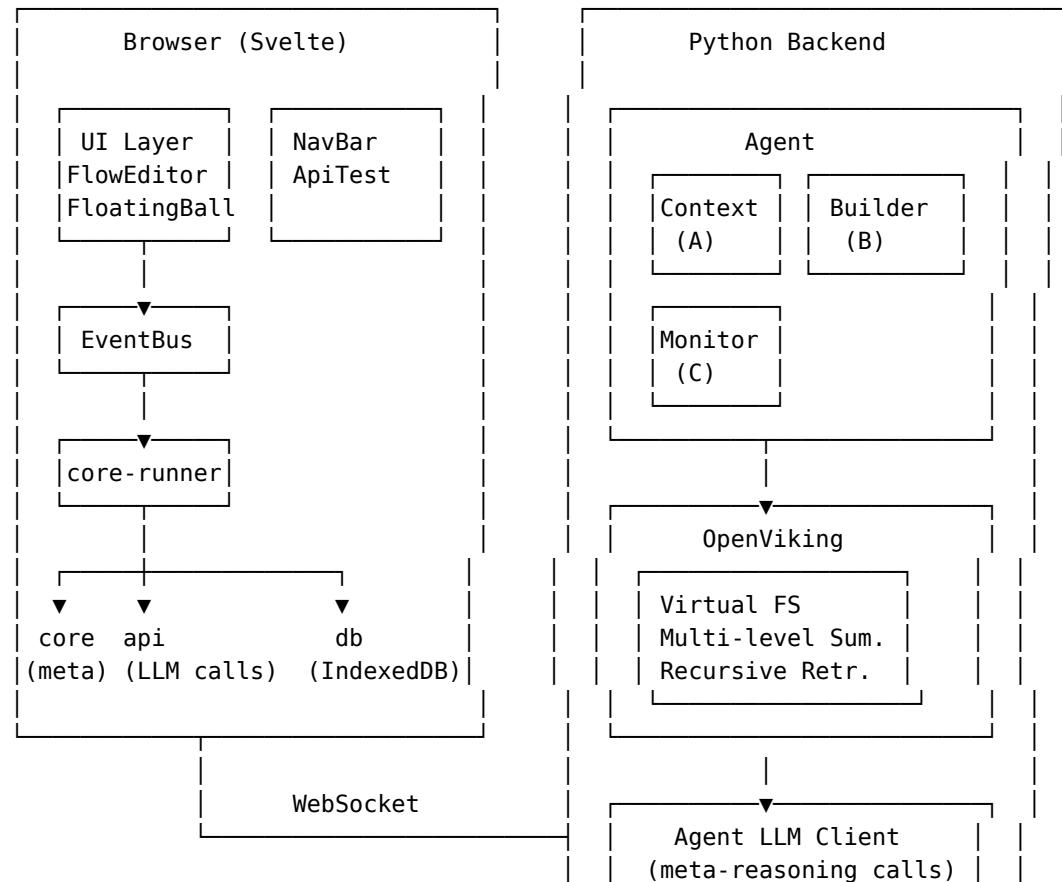
浏览器端的简易上下文方案 (IndexedDB + Embeddings API) 无法满足：

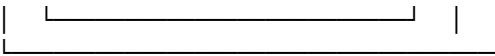
- 缺乏虚拟文件系统语义，无法追踪上下文来源
- 缺乏多级摘要能力
- 缺乏递归式上下文检索

OpenViking 是 Python 项目，因此 FlowCabal 必须引入 Python 后端。

整体架构

客户端-服务端分离





职责划分

职责	Browser	Python
UI 渲染与交互	Yes	
工作流 metadata 编辑	Yes	
工作流持久化 (IndexedDB)	Yes	
LLM API 调用 (用户的 key)	Yes	
工作流执行引擎 (core-runner)	Yes	
Agent 推理 (meta-reasoning)		Yes
上下文管理 (OpenViking)		Yes
输出质量评估		Yes
工作流构建建议		Yes
实体追踪/摘要		Yes

两套 LLM 配置

配置	用途	位置	典型模型
用户 LLM 配置	工作流节点的创作生成	Browser (API key 不离开客户端)	Claude Opus / GPT-4
Agent LLM 配置	元推理：评估、摘要、检索、建议	Python Backend	Claude Haiku / GPT-4o-mini

用户的 API key 始终留在浏览器端，不传输给后端。Agent 使用独立的（通常更廉价的）模型进行元推理。

Agent 系统设计

统一 Agent 循环

三个角色 (A/B/C) 共享同一个 observe → reason → act 循环，由不同事件触发：

角色	触发时机	观察	推理	行动
B: Builder	执行前	用户意图 + 项目上下文	需要什么结构？	创建/修改节点和 prompt
A: Context	执行中 (每节点前)	当前节点 + 项目知识	此节点需要什么上下文？	注入上下文到 prompt

C: Monitor	执行中 (每节点后)	节点输出 + 质量标准	质量是否达标?	批准 / 重试 / 交由人类
------------	------------	-------------	---------	----------------

Prompt 组装管线

Agent 不修改用户的 TextBlockList (那是持久化的 metadata)。上下文注入是 **临时的**, 仅存在于执行期间:

Layer 1: 静态 prompt (用户的 TextBlockList – 持久化 metadata)

↓

Layer 2: Agent 上下文注入 (临时, 仅本次执行)

↓

Layer 3: VirtualTextBlock 解析 (替换为上游节点输出)

↓

最终 prompt 字符串 → LLM API

```
// core-runner 中的 prompt 组装
function buildPrompt(
  node: NodeDefinition,
  runtimeState: WorkflowRuntimeState,
  agentContext?: AgentContext // 来自 Python Agent 的注入
): { system: string; user: string } {
  let system = resolveTextBlockList(node.apiConfig.systemPrompt, runtimeState);
  let user = resolveTextBlockList(node.apiConfig.userPrompt, runtimeState);

  if (agentContext) {
    system = agentContext.systemPrefix + '\n' + system;
    user = user + '\n' + agentContext.userSuffix;
  }

  return { system, user };
}
```

执行流程 (三角色协作)

用户: "写第三章"

↓

[Role B] Agent 分析项目上下文

- 从 OpenViking 检索: 第1-2章摘要、角色状态、大纲
- 推理: "第三章需要4个节点: 场景铺设、对话、冲突、收束"
- 生成 NodeDefinition + 连接建议
- 通过 WebSocket 发送到浏览器展示
- 用户审批 (可能修改)

↓

用户批准 → workflow:run

↓

[core-runner] 按 Kahn 序执行

 |

 | 节点 K 执行前:

- core-runner → ws → Python Agent
- [Role A] Agent 查询 OpenViking
 - "节点 K 正在写第三章的对话场景"
 - 检索: 角色语音样本、进行中的情节线索、第2章结尾
 - 返回 AgentContext

```

    core-runner ← ws ← Python Agent
    core-runner 注入上下文，调用用户的 LLM

    节点 K 执行后：
    core-runner → ws → Python Agent
    [Role C] Agent 评估输出质量
        → 检查：连续性、风格一致性、prompt 遵循度
        → 决策：approve / retry(附修改建议) / flag(交由人类)
    [Role A] Agent 更新 OpenViking
        → 索引节点 K 输出、更新实体状态、生成摘要
    core-runner ← ws ← Python Agent

    下一个节点...

```

WebSocket 协议

EventBus 通过 WebSocket 桥接浏览器和 Python 后端。以下是完整的消息类型定义。

Browser → Python

```

interface AgentProtocol_BrowserToPython {
    // 连接管理
    'agent:connect': {
        workflowId: string;
        projectId: string; // OpenViking 项目标识
    };
    'agent:disconnect': void;

    // Role B: 工作流构建请求
    'agent:build-request': {
        intent: string; // 用户的自然语言意图
        currentWorkflow?: string; // 当前工作流 JSON (可选)
    };
    'agent:build-accept': {
        suggestionId: string; // 接受某个建议
        modifications?: string; // 用户的修改说明
    };
    'agent:build-reject': {
        suggestionId: string;
        reason?: string;
    };

    // Role A+C: 执行期间
    'agent:node-before': {
        nodeId: NodeId;
        nodeName: string;
        promptPreview: { // 静态 prompt (未注入上下文)
            system: string;
            user: string;
        };
        dependencies: NodeId[]; // 此节点的上游依赖
    };
    'agent:node-output': {
        nodeId: NodeId;
        nodeName: string;
        output: string; // 节点 LLM 输出
    };
}

```

```

    usage?: UsageInfo;
};

// 人类介入响应
'agent:human-decision': {
  nodeId: NodeId;
  decision: 'approve' | 'retry' | 'edit';
  editedOutput?: string; // 如果 decision = 'edit'
};
}

```

Python → Browser

```

interface AgentProtocol_PythonToBrowser {
  // Role B: 工作流建议
  'agent:build-suggestion': {
    suggestionId: string;
    nodes: NodeDefinition[];
    edges: { source: NodeId; target: NodeId }[];
    explanation: string; // Agent 的解释
  };

  // Role A: 上下文注入
  'agent:context-ready': {
    nodeId: NodeId;
    context: {
      systemPrefix: string; // 注入到 system prompt 前
      userSuffix: string; // 注入到 user prompt 后
    };
    sources: string[]; // OpenViking 中的来源路径 (可追溯性)
  };

  // Role C: 质量评估
  'agent:evaluation': {
    nodeId: NodeId;
    decision: 'approve' | 'retry' | 'flag-human';
    confidence: number; // 0-1
    reason: string;
    retrySuggestion?: string; // 如果 retry, 建议修改什么
  };

  // 上下文更新确认
  'agent:context-updated': {
    nodeId: NodeId;
    updatedPaths: string[]; // OpenViking 中更新的文件路径
    newSummaries: string[]; // 新生成的摘要路径
  };

  // 人类介入请求
  'agent:needs-human': {
    nodeId: NodeId;
    reason: string;
    outputPreview: string;
    options: ('approve' | 'retry' | 'edit')[];
  };

  // 状态与错误
}

```

```

'agent:status': {
  status: 'connected' | 'busy' | 'error';
  message?: string;
};

'agent:error': {
  error: string;
  nodeId?: NodeId;
};

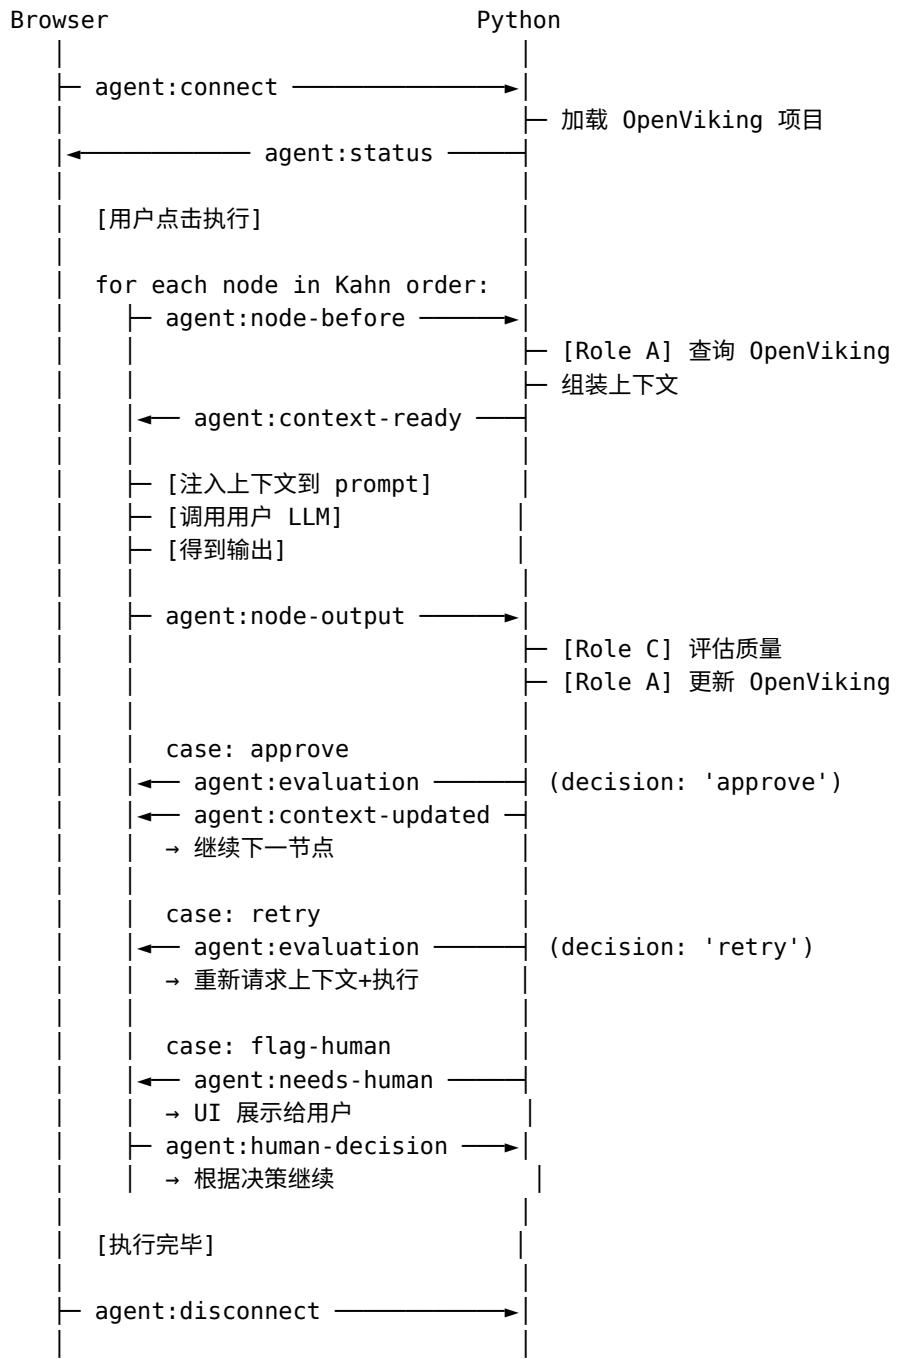
};

}

```

消息流时序

完整执行流程



OpenViking 项目模型

长篇小说的虚拟文件系统结构

```
/project
  |- /meta
    |- outline.md          # 全篇大纲
    |- style-guide.md      # 文风、语气、视角规则
    |- world-rules.md      # 世界观设定与约束
  |- /entities
    |- characters/
      |- protagonist.md    # 状态、关系、弧光
      |- antagonist.md
      |- ...
    |- locations/
      |- ...
    |- plot-threads/
      |- main-thread.md
      |- subplot-1.md
  |- /manuscript
    |- chapter-01/
      |- content.md          # 全文
      |- summary-paragraph.md
      |- summary-sentence.md
      |- entity-changes.json # 本章实体状态变更
    |- chapter-02/
      |- ...
  |- /summaries
    |- arc-1.md            # 多章摘要
    |- arc-2.md
    |- full-work.md         # 全书一页摘要
```

Agent 如何使用 OpenViking

当 Agent 为“第 12 章对话场景”节点准备上下文时，典型检索结果：

```
retrieved = viking.retrieve(
    query="第12章对话场景所需上下文",
    node_context={
        "chapter": 12,
        "scene_type": "dialogue",
        "characters": ["protagonist", "antagonist"]
    }
)
# 可能返回：
# - /summaries/full-work.md          (全局概览)
# - /summaries/arc-3.md              (当前叙事弧)
# - /manuscript/chapter-11/summary-paragraph.md (前章)
# - /entities/characters/protagonist.md
# - /entities/characters/antagonist.md
# - /meta/style-guide.md
```

每次检索的来源路径通过 `agent:context-ready.sources` 传回浏览器，确保可追溯性。

目录结构

浏览器端

```
flow-cabal/src/lib/
├── core/           # metadata 层 (不变)
│   ├── textblock.ts
│   ├── node.ts
│   ├── workflow.ts
│   ├── apiconfig.ts
│   └── index.ts
├── core-runner/    # 执行引擎 (新增)
│   ├── runner.ts    # WorkflowRunner
│   ├── prompt.ts    # Prompt 组装管线 (含 Agent 注入)
│   ├── types.ts     # RuntimeState 类型
│   └── index.ts
├── bus/            # EventBus (新增)
│   ├── eventbus.ts
│   ├── events.ts    # 本地 + Agent 事件类型
│   └── ws-bridge.ts # EventBus ↔ WebSocket 桥接
├── agent-client/  # Agent 客户端 (新增)
│   ├── client.ts    # WebSocket 连接管理、重连、心跳
│   ├── types.ts     # AgentProtocol 类型
│   └── index.ts
├── api/            # LLM 客户端 (不变)
├── db/             # 持久化 (不变)
├── components/    # UI 组件
├── nodes/          # @xyflow 节点组件
└── utils/          # 布局、验证
```

Python 后端

```
backend/
├── server.py       # WebSocket 服务器
├── config.py       # Agent LLM 配置
├── protocol.py    # 消息类型定义 (与 TS 类型镜像)
└── agent/
    ├── core.py      # Agent 主循环 (observe → reason → act)
    ├── context.py   # Role A: OpenViking 查询 + 上下文组装
    ├── builder.py   # Role B: 工作流构建建议
    ├── monitor.py   # Role C: 输出质量评估
    └── skills/
        ├── summarize.py # 多级摘要生成
        ├── retrieve.py  # 上下文检索
        ├── evaluate.py  # 质量评估
        └── entity.py    # 实体追踪与状态管理
└── viking/
    ├── adapter.py   # OpenViking 集成适配器
    └── project.py   # 小说项目结构管理
requirements.txt
```

与之前设计的关系

模块	design_doc.typ (v2)	本文档 (v3)
----	---------------------	----------

core/	不变	不变
core-runner/	独立执行引擎	增加 Agent 上下文注入管线
EventBus	浏览器内 pub/sub	扩展 WebSocket 桥接到 Python
Agent	未涉及	三角角色统一架构 (A/B/C)
上下文管理	未涉及	OpenViking 后端
LLM 调用	浏览器端单一配置	双配置：用户 LLM + Agent LLM
部署模型	纯浏览器	客户端-服务端 (WebSocket)

design_doc.typ 中的 EventBus 类型定义、core-runner 的 RuntimeState 类型、WorkflowRunner 类结构均保持有效，本文档在此基础上扩展。

实施路线

阶段一：基础设施

1. EventBus + WebSocket 桥接
2. core-runner (不含 Agent 注入，先跑通基础执行)
3. UI 层与 core 类型桥接 (消除 @xyflow 直用问题)
4. Python WebSocket 服务器骨架

阶段二：Agent 核心

1. Agent 主循环 (observe → reason → act)
2. Role A: OpenViking 集成 + 上下文检索 + 注入管线
3. Role C: 输出质量评估 + 重试逻辑
4. Prompt 组装管线增加 Agent 层

阶段三：Agent 高级能力

1. Role B: 工作流构建建议
2. 高级查询函数 (递归/迭代 LLM 模式)
3. 节点输出历史 + 冻结
4. 子工作流

阶段四：打磨

1. Agent 对话界面 (FloatingBall 扩展)
2. OpenViking 项目管理 UI
3. 上下文来源可视化 (哪些 OpenViking 路径被注入)
4. 性能优化与错误恢复